

Un protocollo per valutare un agente su nuvole di punti

Quello che presentiamo è lo strumento di misura, non le conclusioni. Con una scena sola nessun numero qui autorizza a generalizzare — ma l'impianto che li produce è costruito perché, quando le scene saranno più di una, le conclusioni quantitative si possano trarre davvero.

60 domande 5 modelli 2 condizioni sperimentali $\kappa = 0,776$
0 righe di codice per aggiungere una scena

LA TESI

Perché difendiamo il metodo e non i risultati

Su una scena l'unità statistica sono le domande, non le scene: qualunque affermazione del tipo «questo modello è migliore su nuvole architettoniche» sarebbe indifendibile. Quello che invece è già difendibile oggi è l'affermazione più utile per il gruppo:

Esiste un apparato che, dato un nuovo rilievo e una giornata di annotazione, produce numeri confrontabili, con un margine d'errore dichiarato e una misura di quanto ci si possa fidare della misura stessa.

Il resto di questo documento è la descrizione di quell'apparato e delle prove che funziona. I risultati sui cinque modelli compaiono in fondo, come dimostrazione che la macchina gira — non come conclusione.

IL SISTEMA SOTTO ESAME

Che cosa risponde alle domande

Da un .laz con etichette semantiche, DBSCAN estrae gli oggetti e ne deriva un grafo spaziale. Su quello si innestano due strati distinti, e la separazione fra i tre è la tesi del progetto, non un dettaglio.

STRATO	CONTENUTO	ORIGINE
L1	grafo spaziale: near, supports, rests_on, is_opening_in	geometria
L2	materiale, tipologia, funzione, descrizione	CSV compilato da un architetto

L3 grafo CIDOC-CRM: tipi, materiali, aggregati

derivato da L1 e L2

Il vincolo che regge tutto: **il materiale non si inferisce mai dalla geometria**. Una colonna è in Breccia policroma perché lo dice il CSV. È anche ciò che rende possibile l'esperimento più avanti: togliendo il CSV, quell'informazione diventa verificabilmente irraggiungibile.

LA SCENA E LE DOMANDE

scena4_VAL

COLUMN 6	WALL 11	DOOR_WINDOW 8	MOLDINGS 6	FLOOR 1
VAULT 1	ARCH · ROOF · STAIRS 0 assenti			

Le tre classi assenti reggono **14 domande su 60**. Un modello che risponde «due scale collegano i livelli» ha inventato un pezzo di edificio: è la trappola per allucinazioni attorno a cui il set è costruito, e la famiglia che separa i modelli più di ogni altra.

IL METODO — PARTE PRIMA

Perché non si valuta la prosa

Il primo validatore cercava espressioni regolari nel testo intero. Il rapporto di settembre lo diceva apertamente: il tasso automatico «sottostima sensibilmente la qualità reale del run». Falliva così:

- «8 door_window» letto come «8 oggetti in tutto nella scena».
- «roof: 0» letto come affermazione che il tetto è presente.
- Gli identificatori numerati negli elenchi scambiati per conteggi.

Non è un problema di soglie. Si stava confrontando **prosa** con **fatti**, quindi il punteggio dipendeva dallo stile di scrittura: un modello che formatta in elenchi markdown veniva punito rispetto a uno che scrive frasi distese, a parità di correttezza.

Ridurre la risposta a ciò che afferma

La valutazione è spezzata in due passi. Prima la risposta viene ridotta a un insieme normalizzato di affermazioni; solo dopo, quelle vengono confrontate con il riferimento.

L'estrazione è **a regole, non con un secondo LLM**: il dominio è chiuso e lo conosciamo per intero — dieci classi con i loro sinonimi italiani e inglesi, quattordici tipi di relazione, identificatori con un unico schema. Un estrattore LLM aggiungerebbe una seconda fonte di errore che nessuno sta misurando.

RISPOSTA · LLAMA3.1 · Q18 «Sì. Le colonne sono elementi strutturali, in quanto supportano il tetto.» ruoli {structural} relazioni {(column, supports, roof)} ESITO NON CORRETTO — ROOF NON ESISTE NELLA SCENA	RISPOSTA · GEMMA4:31B · Q6 «- wall: 11 · - door_window: 8 · - column: 6» conteggi {wall: 11, door_window: 8, column: 6} totale nessuno dichiarato ESITO CORRETTO — IL NUMERO SI LEGA AL NOME DI CLASSE PIÙ VICINO
---	--

L'affermazione su una classe assente è **squalificante**, non un errore parziale. Contano tre cose: nominarne un oggetto, contarne, metterla in relazione. Una menzione nuda non basta — la tipologia nel CSV è letteralmente «apertura ad arco» e la funzione della volta è una «copertura», quindi quelle parole compaiono in risposte sane.

Un criterio per ogni tipo di domanda

FAMIGLIA	DOMANDECONFRONTO
Valore esatto	18conteggio, materiale o ruolo atteso
Assenza	11la risposta nega la premessa
Insiemi	11precision e recall sull'insieme
Coerenza con i tool	4ogni relazione citata esiste nell'output dello strumento
Conteggi, per oggetto, relazioni, coordinate	6dizionario, attributi, triple, tolleranza 0,02 m

*Interpretative**10 non valutate automaticamente*

Cinquanta domande su sessanta sono verificabili senza giudizio umano. Le altre restano fuori dal conteggio invece di essere contate come sbagliate: una copertura dichiarata vale più di un'accuratezza gonfiata.

Lo scoring è **disaccoppiato dall'esecuzione**: rilegge le risposte già salvate. Migliorare il giudizio costa un rilancio dello script, non un'ora di GPU. È la ragione per cui è stato possibile correggerlo dodici volte in pochi giorni senza rifare un solo benchmark — e la ragione per cui il protocollo può ancora evolvere senza invalidare i dati.

IL METODO — PARTE QUARTA

Validare il validatore

A questo punto lo scorer produce numeri, ma nulla dice che coincidano con il giudizio di una persona. Misurarlo è il passo che rende presentabile tutto il resto — ed è il passo che la maggior parte delle valutazioni automatiche salta.

- Campione stratificato per modello**
Sessanta risposte, dodici per modello, seme fisso. Stratificate per modello e **non** per verdetto dello scorer: bilanciare fra corrette e sbagliate cambierebbe le frequenze marginali, ed è da quelle che κ si calcola.
- Annotazione cieca**
L'annotatrice vede domanda, risposta e fatto atteso. Non vede il verdetto automatico, che sta in un file separato. Chi vede prima il verdetto lo conferma, non lo valida.
- Regole di giudizio dichiarate prima**
Parziale vale non corretto; lingua e formulazione non contano; astenersi è corretto solo quando il dato davvero manca; inventare è sempre sbagliato. Senza regole comuni, κ misura un disaccordo di definizione invece che di giudizio.
- Accordo corretto per il caso**
Due valutatori che dicono «corretto» nell'80% dei casi si accordano nel 70% per puro caso. L'accordo grezzo non è una misura; κ toglie quella quota.

93,0%

accordo grezzo

68,6%

atteso per caso

0,776Cohen's κ · IC 95% [0,52–0,95]

	scorer: corretto	scorer: sbagliato
umano: corretto	44	4
umano: sbagliato	0	9

Zero in basso a sinistra: lo scorer non ha mai accettato una risposta che una persona giudica sbagliata. Sbaglia solo per eccesso di severità, il che rende le accuratezze **limiti inferiori**. Per un benchmark che misura allucinazioni, è la direzione giusta in cui sbagliare.

L'ARGOMENTO CENTRALE

Il metodo ha trovato i propri errori

La prima misura è uscita a $\kappa = 0,387$: non presentabile. È il risultato più importante dell'intero lavoro, perché il disaccordo non era rumore — **indicava dove guardare**, e in due direzioni diverse.

DOPO	K	DISACCORDICHE COSA ERA EMERSO
prima misura	0,387	16—
correzione dell'estrattore	0,515	115 difetti di parsing
correzione del riferimento	0,776	46 difetti del gold stesso

I difetti dell'estrattore erano cose come: la finestra di negazione scalcava il confine di frase, un «Sì.» iniziale letto come risposta affermativa invece che come segnale di discorso, le relazioni scritte `supports (floor → column)` illeggibili.


I difetti del riferimento erano più interessanti: Q29 pretendeva un materiale del pavimento in contraddizione con il CSV; Q4 pretendeva che i modelli nominassero `other`, che è una pseudo-classe; quattro domande pretendevano fatti veri **che la domanda non chiede**. A «di che materiale sono i muri?» si risponde con il materiale, non anche con il numero di oggetti annotati.

Questo è l'argomento da difendere in riunione. Non «i nostri numeri sono giusti», ma **«abbiamo un modo per accorgerci quando non lo sono, e ha funzionato due volte su due»**. Dei quattro disaccordi residui, tre non sono nemmeno dello scorer: due annotazioni generose e una risposta che dà un conteggio dove la domanda chiedeva un elenco.

Vale la pena aggiungere che l'errore è attribuibile su **due livelli indipendenti**: `validate_triples` misura il grafo spaziale contro un gold annotato da un architetto, lo scorer misura l'LLM contro il riferimento. Quando l'agente sbaglia si può dire di chi è la colpa. Gran parte della letteratura LLM+grafo di conoscenza non separa i due livelli.

Quali differenze sono reali

Tutti i modelli rispondono **alle stesse domande**: i dati sono appaiati. Con 50 item l'intervallo su una proporzione attorno all'80% è di circa ± 11 punti — confrontare due accuratezze come campioni indipendenti non farebbe passare quasi nulla. Il test di McNemar guarda solo le domande su cui i due modelli divergono, nella forma esatta perché le discordanze sono poche, con correzione di Bonferroni sui dieci confronti.



Triangolo inferiore, modelli ordinati per accuratezza. Blu dove la differenza si risolve, grigio dove no.

gemma4:31b non è «il migliore». Il suo 90% contro l'86% di gpt-oss non supera il test. Ciò che i dati sostengono è una struttura a fasce, non una classifica — ed è esattamente il tipo di disciplina che il protocollo serve a imporre.

Una manipolazione controllata


La seconda condizione sperimentale toglie il layer CSV. Non nascondendo gli strumenti, ma **non caricandolo affatto**: i valori finiscono nei nodi del grafo, quindi nasconderli soltanto avrebbe lasciato che

un tool geometrico li rivelasse.

Segmentazione, feature e grafo spaziale restano identici — 33 oggetti e 170 archi in entrambe le condizioni. **L'unica variabile manipolata è la disponibilità della conoscenza umana.**

Quando il dato non c'è, il modello lo dice?

Condizione senza CSV: materiale, tipologia e funzione non sono caricati. La risposta corretta è dichiararlo.




Nessuna risposta prodotta non è un'allucinazione: è il ciclo dell'agente che si interrompe dopo la chiamata allo strumento. Le due cose sono tenute separate perché hanno cause diverse e richiedono interventi diversi.

Le 11 domande su materiale, tipologia e funzione, con il CSV non caricato. La risposta corretta è dichiarare che il dato non è raggiungibile.

I tre esiti sono tenuti separati per una ragione metodologica. **command-r sembrerebbe il peggiore con zero astensioni — ma non inventa: non risponde affatto**, dieci volte su undici. È il ciclo dell'agente che si interrompe, non un'allucinazione. Collassare le due cose avrebbe raccontato il falso su quel modello.

Quanto vale il layer CSV

Stessi modelli, stesse domande, con e senza le annotazioni dell'architetto




Le 11 domande che dipendono dal CSV sono escluse: senza CSV la risposta corretta non è il valore ma dichiararne l'assenza, e confrontarle misurerebbe due compiti diversi. L'asterisco marca le differenze che superano il test di McNemar esatto.

Confronto appaiato sulle 42 domande la cui risposta attesa non cambia fra le condizioni. Le 11 che dipendono dal CSV sono escluse: senza CSV la risposta corretta non è il valore ma dichiararne l'assenza, e confrontarle misurerebbe due compiti diversi.

Tutti peggiorano senza il CSV, ma solo due differenze si risolvono: gpt-oss -24 punti ($p = 0,006$) e qwen3.5 -26 ($p = 0,035$). Va letto accanto a un secondo dato: **le risposte vuote passano da 0 a un intervallo fra 5 e 15**. Parte di ciò che sembra un calo di ragionamento è l'agente che smette di produrre output.

RISULTATI

Dove i modelli cedono



Percentuale di risposte pienamente corrette. Le colonne portano il numero di domande dietro ogni cella, e una riga separa le famiglie che poggiano su quattro domande o meno.

Il profilo d'errore è più informativo del posizionamento. **qwen3.5** ha l'accuratezza più alta sui valori singoli (95%) ma crolla sugli insiemi (45%): azzecca il numero e sbaglia l'elenco. **command-r** incapsula gli argomenti dei tool in uno schema che l'adattatore non riconosce — la sua difficoltà non è architettonica ma di protocollo.

IL PASSO SUCCESSIVO

Che cosa serve per la scena 2

SERVE	COSTO	CHI
Il rilievo .1az con etichette semantiche	—	già disponibile
Il CSV di annotazione	mezza giornata	architetto
Riferimento strutturato per le 60 domande	una giornata	annotatore
Esecuzione dei benchmark, due condizioni	~1 ora di GPU	automatico
Scoring, κ , McNemar, figure	minuti	automatico
Modifiche al codice	nessuna	—

È questa la riga che conta per il gruppo: l'apparato non contiene nulla di specifico alla scena4. Estrattore, scorer, condizioni, annotazione cieca, test statistici e figure leggono tutti dal riferimento strutturato. **Con tre o quattro scene le conclusioni quantitative diventano legittime**, e il costo marginale di ciascuna è una giornata di annotazione.

LIMITI

Che cosa questi numeri non dicono

- **Una scena sola.** Nulla qui autorizza a generalizzare ad altre geometrie o dataset.
 - **Dieci domande su sessanta** restano al giudizio umano: la copertura dell'83% è dichiarata, non aggirata.
 - **L'intervallo su κ è largo** — [0,52 – 0,95] su 57 voci. La cifra puntuale non va letta come precisa.
 - **Il parametro think non ha avuto effetto:** fra varianti attive e disattive cambiano da zero a cinque risposte su sessanta, con latenze identiche.
 - **Lo scorer sbaglia per severità**, quindi le accuratezze sono limiti inferiori.
 - **Quattro disaccordi con l'annotazione restano aperti**, tre dei quali riguardano l'annotazione e non lo scorer.
-

Benchmark del 17 settembre 2026 (condizione completa) e del 22 settembre (condizione senza CSV) su scena4_VAL, cinque modelli Ollama locali. Riferimento strutturato approvato e revisionato il 23 settembre dopo la validazione con annotazione umana. Tutte le metriche e le figure sono rigenerabili dai report grezzi senza rilanciare i modelli.